Deep Learning in Bioinformatics

Practice

DATA MINING & BIOINFORMATICS LAB.



Index —

- 1. Deep Learning Process
- 2. Sequence Classification
- 3. Link Prediction (Graph Neural Network)

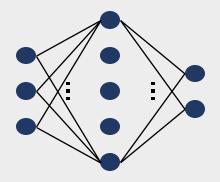


Step1

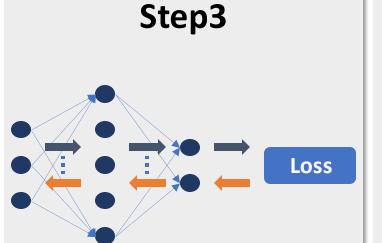


- Collecting data
- Preprocessing
- Dataset
- Data-loader

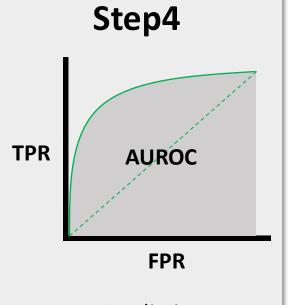
Step2



- Selecting method
- Building model



- Hyper-parameters
- Loss function
- Optimizer
- Training



- Predicting
- Evaluating



Sequence Classification



Dataset

DeepLoc 2.0 provides proteins categorized into one of multiple of theses ten locations

: Cytoplasm, Nucleus, Extracellular, Cell membrane, Mitochondrion, Plastid, Endoplasmic reticulum, Lysosome/Vacuole, Golgi apparatus, Peroxisome.

ACC	Kingdom	Partition	Membrane	Cytoplasm	Nucleus		Sequence
Q28165	Metazoa	4	0	1	1		MAAAAAAAAAGAAG
Q86U42	Metazoa	4	0	1	1		MAAAAAAAAAGAAG
Q0GA42	Metazoa	3	1	0	0		MAAAAAAAAALGVRL
P82349	Metazoa	1	1	1	0		MAAAAAAAATEQQG
Q7L5N1	Metazoa	1	0	1	1	•••	MAAAAAAAATNGTG
Q96S94	Metazoa	0	0	0	1		MAAAAAAAGAAGSAA
Q9CQ25	Metazoa	0	0	1	0		MAAAAAAAGGAALAV
Q96P70	Metazoa	4	0	1	1		MAAAAAAGAASGLPG
P63086	Metazoa	1	1	1	0		MAAAAAAGPEMVRGQ



Dataset

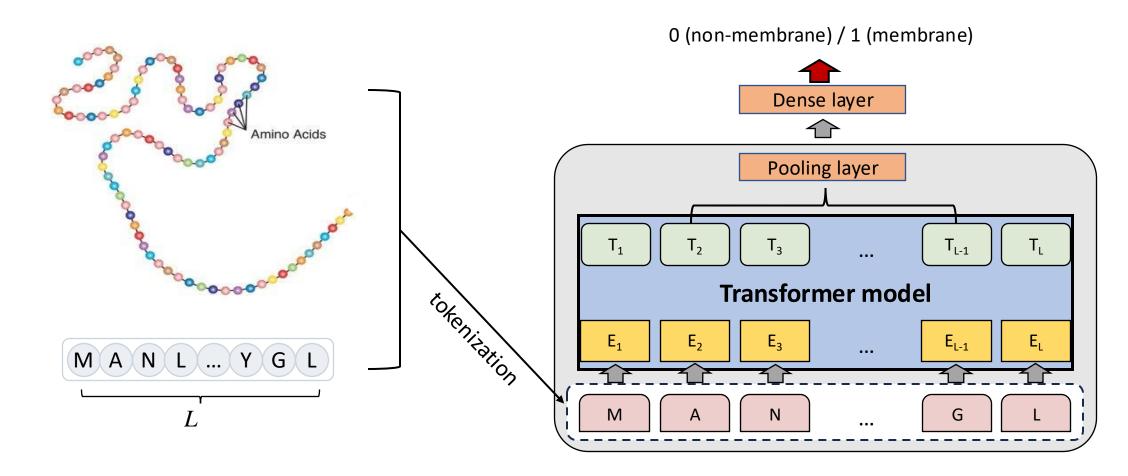
Toy dataset – DeepLoc2.0_membrane

index	асс	sequence	label
0	P63086	MAAAAAAGPEMVRGQ	1
1	Q9UID3	MAAAAAAGPSPGSGP	0
2	P51788	MAAAAAEEGMEPRAL	1
3	Q3UCQ1	MAAAAALSGAGAPPA	0
4	Q9NVF7	MAAAAEERMAEEGGG	0
5	Q8CD10	MAAAAGRSAWLAAWG	1
6	Q5VY80	MAAAAIPALLLCLPL	1
7	Q96IV0	MAAAALGSSSGSASP	0
8	O35094	MAAAALRGGWCRCPR	1
9	Q9Y584	MAAAAPNAGGSAPET	1
10	Q9NXG6	MAAAAVTGQRPETAA	1
•••		•••	



Model

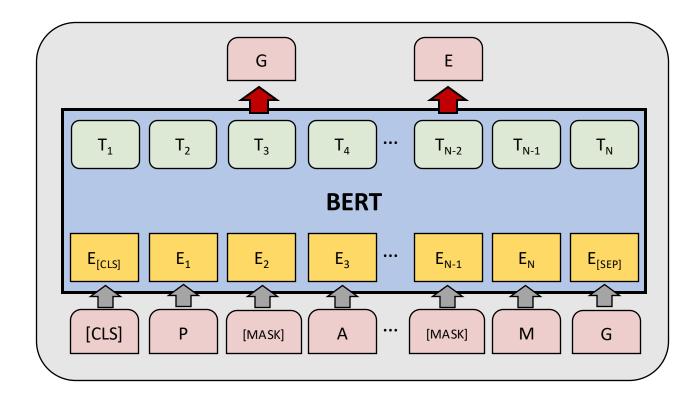
- Protein sequence binary classification
 - Sequence classification is the task of assigning a label or class to a given text.
 - Input : protein sequence
 - Target: binary classification (membrane or non-membrane)



Model

Pre-training model – ProtBERT

- "Prottrans: Toward understanding the language of life through self-supervised learning."
- Bert-based protein language model developed as part of the *Prottrans* project.
- ProtBERT is trained in self-supervised manner, essentially learning to predict masked amino acids (tokens) in already known sequences.

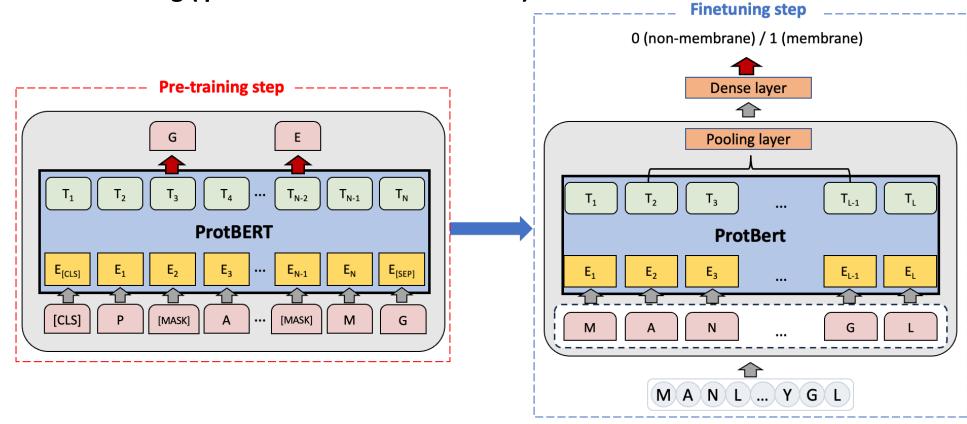




Model

- Protein sequence binary classification
 - Sequence classification is the task of assigning a label or class to a given text.
 - Input: protein sequence
 - Target: binary classification (membrane or non-membrane)

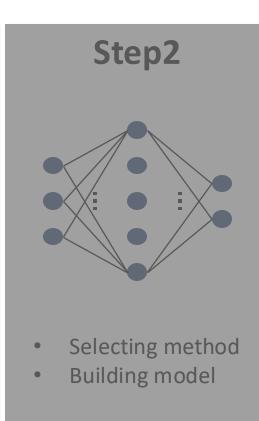
Transfer learning (pretrained model: ProtBERT)

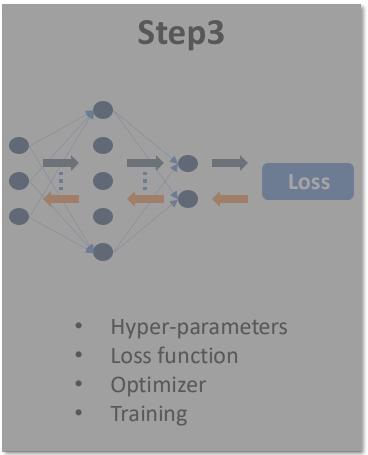


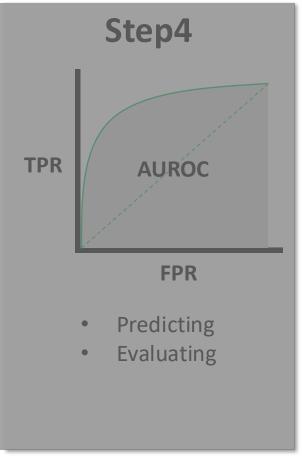
Step1



- Collecting data
- Preprocessing
- Dataset
- Data-loader









Step 1. Load dataset -

```
1 ### Load dataset ###
2 train_df = pd.read_csv('./toy_train.csv')
3 valid_df = pd.read_csv('./toy_valid.csv')
4
5 train_df.head()
```

	index	acc	sequence	labels
0	0	P63086	MAAAAAAGPEMVRGQVFDVGPRYTNLSYIGEGAYGMVCSAYDNLNK	1
1	1	Q9UID3	MAAAAAAGPSPGSGPGDSPEGPEGEAPERRRKAHGMLKLYYGLSEG	0
2	2	P51788	MAAAAAEEGMEPRALQYEQTLMYGRYTQDLGAFAKEEAARIRLGGP	1
3	3	Q3UCQ1	MAAAAALSGAGAPPAGGGAGGGSPPGGWAVARLEGREFEYLMKKR	0
4	4	Q9NVF7	MAAAAEERMAEEGGGGQGDGGSSLASGSTQRQPPPPAPQHPQPGSQ	0



Step 1. Load dataset

- Dataset은 데이터를 효율적으로 관리하고, 정형화된 방식으로 데이터를 가져오기 위함
- __getitem__과 __len__을 구현하여 데이터 접근과 크기 확인이 용이함
- 다양한 전처리를 쉽게 적용할 수 있음

```
1 train_dataset = ProteinDataset(train_df)
2 valid_dataset = ProteinDataset(valid_df)
```



Step 1. Load dataset -

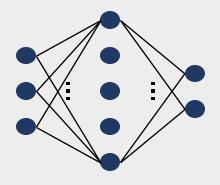
• Dataloader는 Batch 단위로 데이터를 나누어 효율적인 배치 학습을 가능하게 함

```
1 train_loader = DataLoader(train_dataset, batch_size=batch_size, shuffle=True)
2 valid_loader = DataLoader(valid_dataset, batch_size=batch_size, shuffle=False)
```

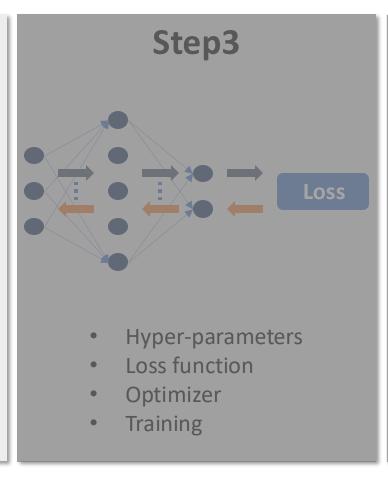


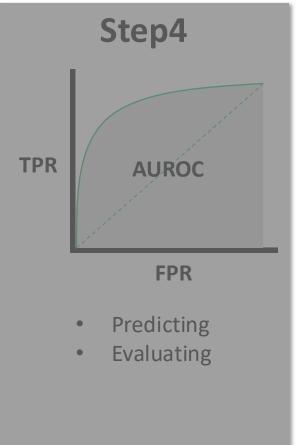
Step1 Data Data Data Collecting data Preprocessing Dataset Data-loader

Step2



- Selecting method
- Building model

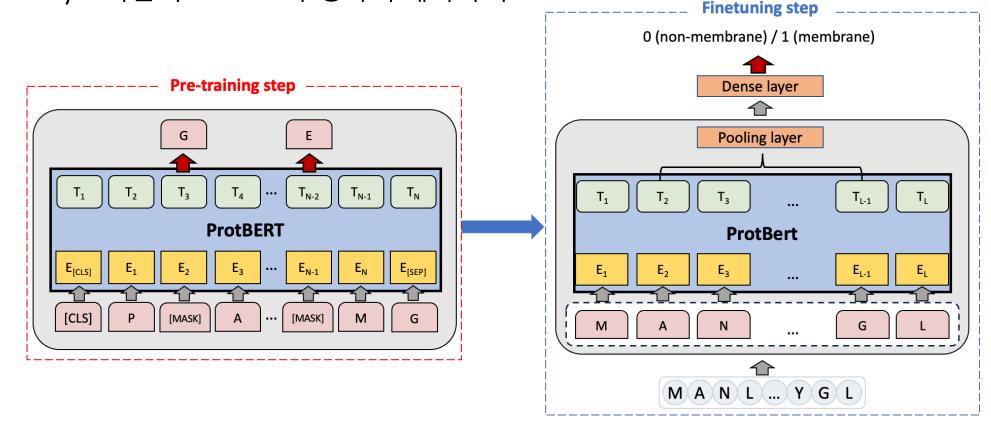






- Protein sequence를 tokenization 하기
- Pretrained ProtBERT 불러오기
- 불러온 protBERT를 사용하여 amino-acid embedding 만들기
- Protein-level embedding을 위하여 amino-acid embedding들을 pooling하기

• Dense layer 기반의 classifier 구성하여 예측하기

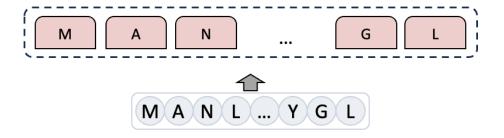


- Protein sequence를 tokenization 하기
- Pretrained ProtBERT 불러오기
- 불러온 ProtBERT를 사용하여 amino-acid embedding 만들기
- Protein-level embedding을 위하여 amino-acid embedding들을 pooling하기
- Dense layer 기반의 classifier 구성하여 예측하기

```
self.tokenizer = BertTokenizer.from_pretrained(pretrained_model_name)

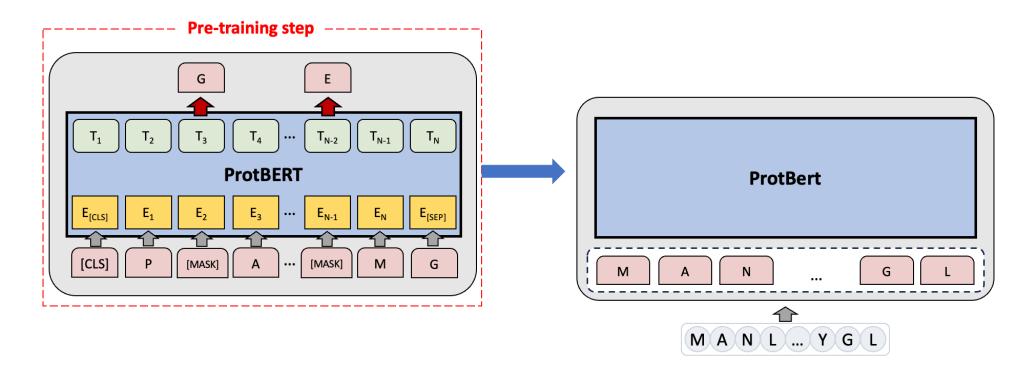
inputs = self.tokenizer.batch_encode_plus(
sequences, add_special_tokens = False,
max_length = 512,
padding=True,
truncation=True

)
```



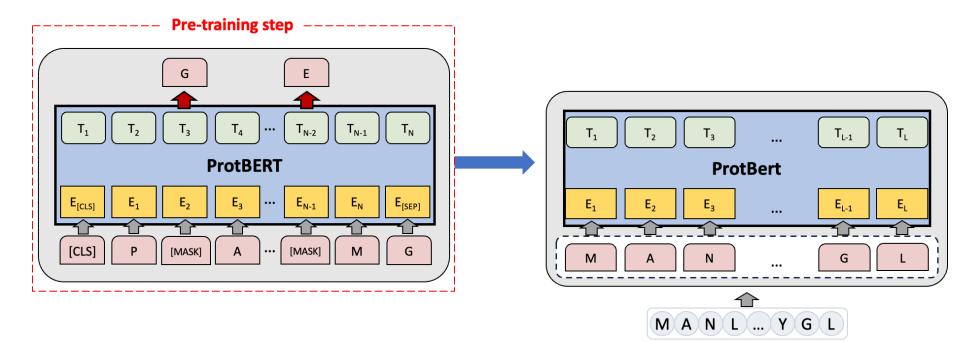
- Protein sequence를 tokenization 하기
- Pretrained ProtBERT 불러오기
- 불러온 ProtBERT를 사용하여 amino-acid embedding 만들기
- Protein-level embedding을 위하여 amino-acid embedding들을 pooling하기
- Dense layer 기반의 classifier 구성하여 예측하기

6 self.encoder = BertModel.from_pretrained(pretrained_model_name)



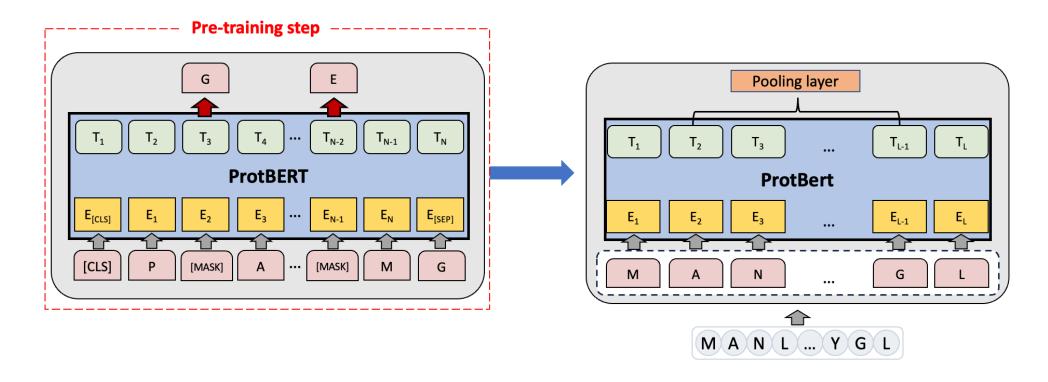
- Protein sequence를 tokenization 하기
- Pretrained ProtBERT 불러오기
- 불러온 ProtBERT를 사용하여 amino-acid embedding 만들기
- Protein-level embedding을 위하여 amino-acid embedding들을 pooling하기
- Dense layer 기반의 classifier 구성하여 예측하기

```
embeddings = self.encoder(
input_ids=torch.tensor(inputs["input_ids"]).to(self.device),
attention_mask=torch.tensor(inputs["attention_mask"]).to(self.device)
)
```



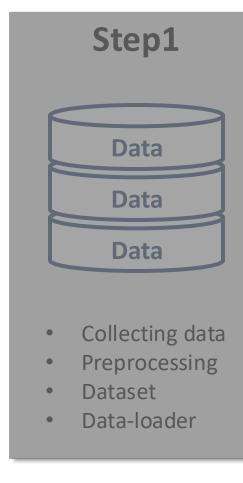
- Protein sequence를 tokenization 하기
- Pretrained ProtBERT 불러오기
- 불러온 ProtBERT를 사용하여 amino-acid embedding 만들기
- Protein-level embedding을 위하여 amino-acid embedding들을 pooling하기
- Dense layer 기반의 classifier 구성하여 예측하기

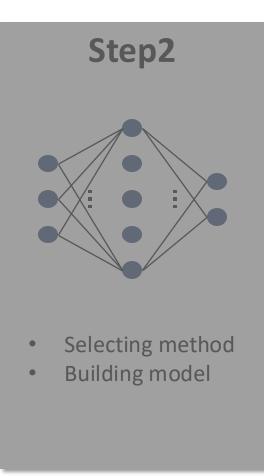
pooled_embeddings = torch.mean(embeddings[0], dim=1)

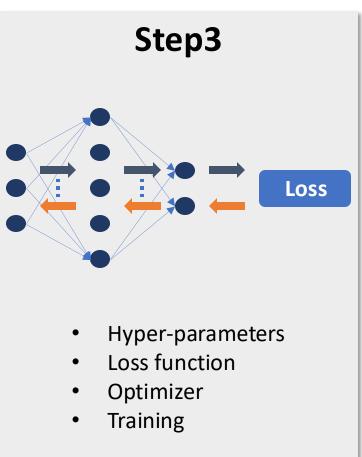


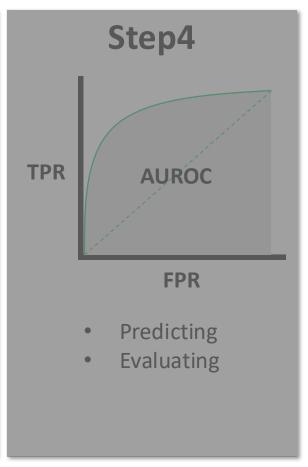
- Protein sequence를 tokenization 하기
- Pretrained ProtBERT 불러오기
- 불러온 ProtBERT를 사용하여 amino-acid embedding 만들기
- Protein-level embedding을 위하여 amino-acid embedding들을 pooling하기
- Dense layer 기반의 classifier 구성하여 예측하기

```
13
           lavers = []
           layers.append(nn.Linear(self.input_dim, hidden dim))
14
15
           layers.append(nn.ReLU())
16
           layers.append(nn.Dropout(dropout))
17
           for in range(num layers - 2):
               layers.append(nn.Linear(hidden_dim, hidden_dim))
18
                                                                                                                             Finetuning step
19
               layers.append(nn.ReLU())
20
               layers.append(nn.Dropout(dropout))
                                                                                                                       0 (non-membrane) / 1 (membrane)
21
           layers.append(nn.Linear(hidden dim, num classes))
22
           self.classifier = nn.Sequential(*layers)
                                                                                                                               Dense layer
                                                                                                                              Pooling layer
         logits = self.classifier(pooled embeddings)
37
                                                                              ProtBERT
                                                                                                                               ProtBert
                                                                                                                         MANL ... YGL
```











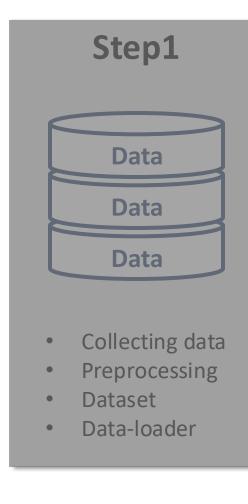
```
1 # 주요 설정
2 device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
3
4 pretrained_model_name = "Rostlab/prot_bert"
5 num_classes = 2 # membrane or non-membrane
6 hidden_dim = 64 # 히든 레이어의 차원
7 num_layers = 3 # 레이어 수
8 batch_size = 64
9 epochs = 1 # 최대 에포크 수
10 learning_rate = 0.001
11 dropout = 0.0 # 드롭아웃 확률
```

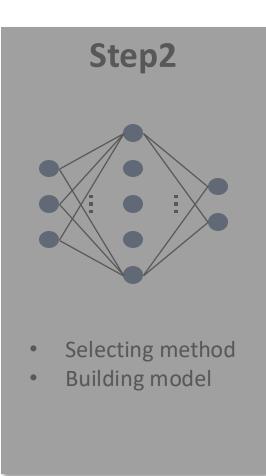
```
1 # 모델 초기화
2 model = DeeplocPredictor(pretrained_model_name, hidden_dim, num_classes, device, num_layers=num_layers, dropout=dropout).to(device)
3 criterion = nn.CrossEntropyLoss()
4 optimizer = torch.optim.AdamW(filter(lambda p: p.requires_grad, model.parameters()), lr=learning_rate)
```

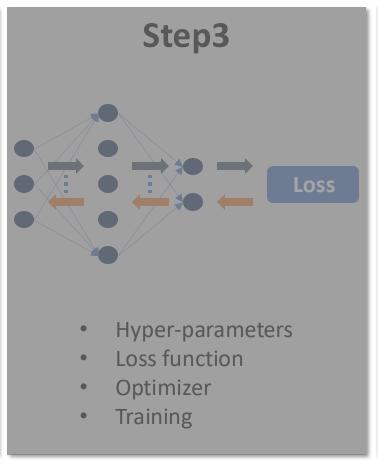


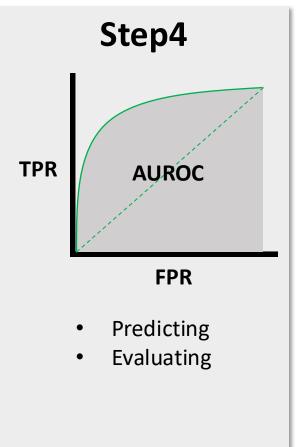
- Epoch : 데이터셋 전체를 한 번 학습하는 주기
- Batch: 데이터셋을 나눈 작은 묶음
- Training loop는 각 epoch마다 모든 batch를 반복 학습하며, 각 batch마다 모델이 손실(loss)을 계산하고, 이를 통해 역전파 (backpropagation)로 가중치를 업데이트 하는 과정

```
# 사용자가 정의한 epoch 만큼 학습 진행
for epoch in range(epochs):
 model.train()
                            # model을 training mode로 변경
                             # batch 마다 모델 파라미터를 업데이트
 for batch in train_loader :
                            #모델에 batch를 입력으로 넣어 output 계산
  outputs = model(batch)
  loss = criterion(outputs, labels) # output과 label 사이의 오차 (loss) 계산
                            # loss function의 gradient를 계산
  loss.backward()
                            #계산된 gradient를 기반으로 하여 weight update 진행
  optimizer.step()
                            # 다음 step을 위하여 gradient 초기화
  optimizer.zero_grad()
```











Step 4. Evaluation

- Validation 단계에서는 모델의 성능을 평가하는 과정이므로 가중치 업데이트를 진행하지 않음
- model.eval()을 호출하여 모델을 평가모드로 전환
- With torch.no_grad()를 사용하여 미분 계산을 비활성화하여 메모리 사용을 줄이고, 계산 속도를 높임

```
# 사용자가 정의한 epoch 만큼 학습 진행
for epoch in range(epochs):
                               # model을 evaluation mode로 변경
 model.eval()
                              # gradient 계산 비활성화
 with torch.no_grad():
                                 # batch 마다 forward propagation 진행
  for batch in valid loader:
                               #모델에 batch 를 입력으로 넣어 output 계산
    outputs = model(batch)
    loss = criterion(outputs, labels) # output과 label 사이의 오차 (loss) 계산
```

Visualization

```
1 # TensorBoard writer 초기화

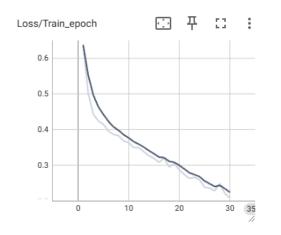
2 tensorboard_log_dir = "runs/deeploc_membrane_prediction"

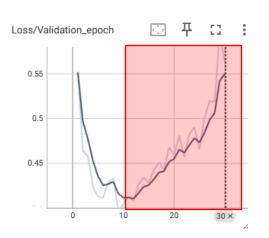
3 os.makedirs(tensorboard_log_dir, exist_ok=True)

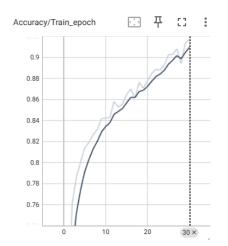
4 writer = SummaryWriter(tensorboard_log_dir)
```

```
# TensorBoard에 Training 기록
writer.add_scalar('Loss/Train', avg_train_loss, epoch + 1)
writer.add_scalar('Accuracy/Train', train_accuracy, epoch + 1)
```

```
# TensorBoard에 Validation 기록
writer.add_scalar('Loss/Validation', avg_val_loss, epoch + 1)
writer.add_scalar('Accuracy/Validation', val_accuracy, epoch + 1)
```









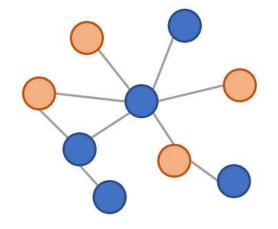


Link Prediction

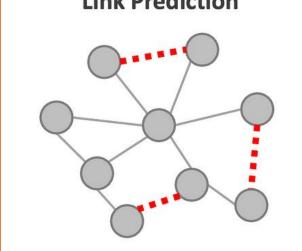


Tasks of Graph

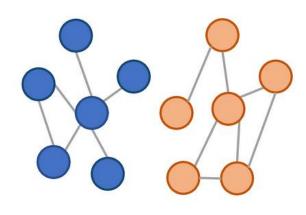
Node Classification



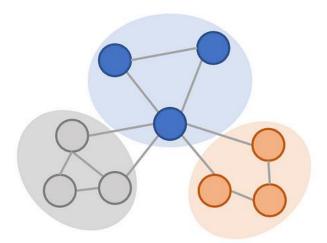
Link Prediction



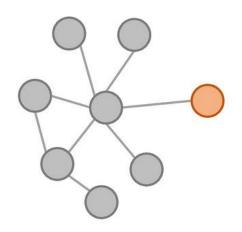
Graph Classification



Community Detection



Anomaly Detection



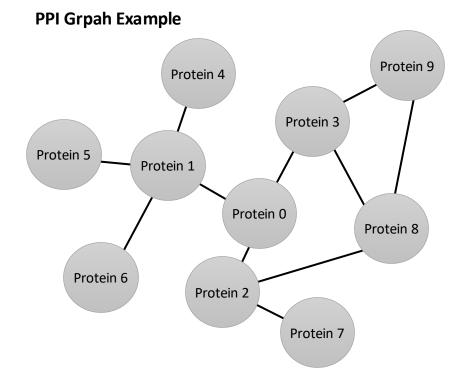


Dataset

PPI (Protein-Protein Interaction)

- This networks from the <u>"Predicting Multicellular Function through Multi-layer Tissue Networks"</u> paper
- Containing 50 features (positional gene sets, motif gene sets and immunological signatures, ...)
- https://pytorch-geometric.readthedocs.io/en/stable/generated/torch_geometric.datasets.PPI.

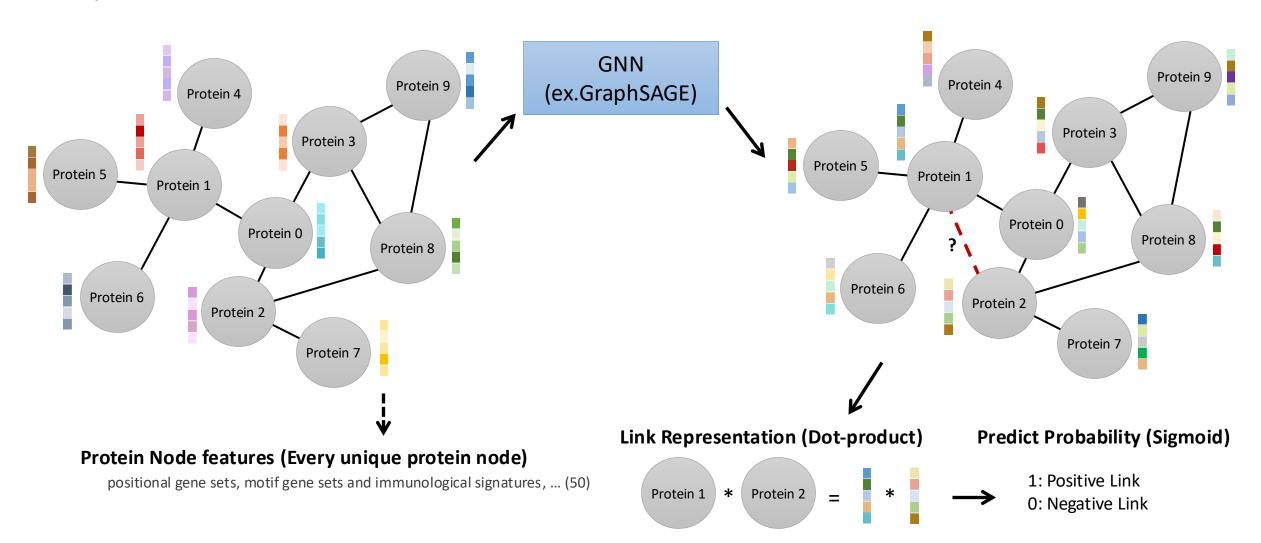
#graphs	#nodes	#edges	#features
20	~2,245.3	~61,318.4	50





Link Prediction

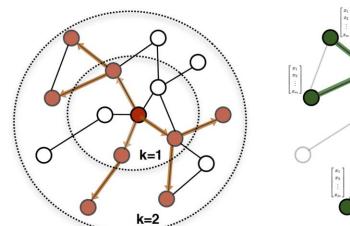
Pipeline

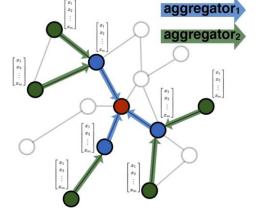


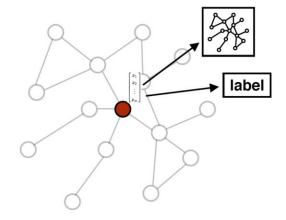


GNN Model

GraphSAGE https://arxiv.org/pdf/1706.02216







1. Sample neighborhood

2. Aggregate feature information from neighbors

3. Predict graph context and label using aggregated information

1. 특정 단백질의 주변 이웃을 샘플링

사용자가 정의한 k-hop 단계의 이웃을 포함하여 정보를 추출

2. 이웃 특징 정보 집계

샘플링된 이웃의 특징 벡터를 학습 가능한 집계 함수(aggregator)를 사용하여 통합 Aggregator에는 Mean, LSTM, Pooling 등이 사용될 수 있음

3. 그래프 문맥과 노드 레이블 예측

집계된 정보를 바탕으로 단백질의 기능 또는 소속 그룹(노드 레이블)을 예측전체 그래프의 문맥을 반영하여 단백질 간의 관계를 파악할 수 있음



Environment

- Python3
 - Pytorch

pip install torch

• Pytorch Geometric

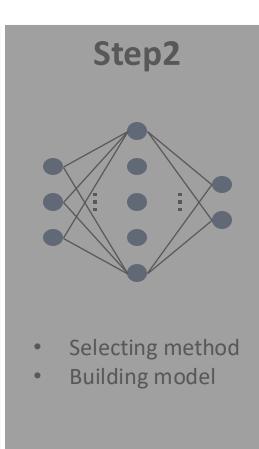
pip install torch-geometric

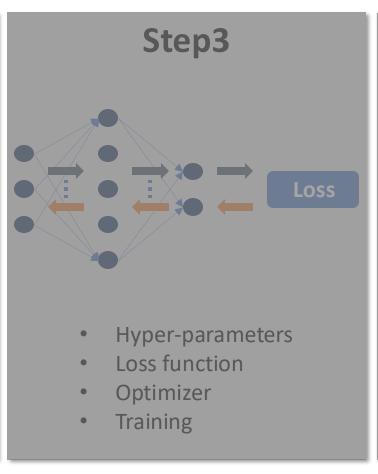


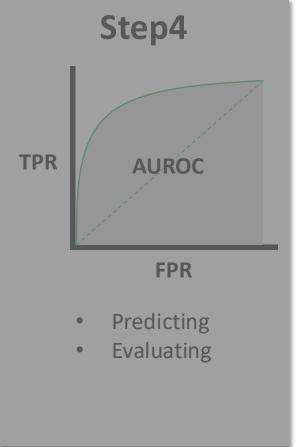
Step1



- Collecting data
- Preprocessing
- Dataset
- Data-loader









Step 1. Load dataset

그래프 전체 구성: data → Data(x=[1767, 50], edge_index=[2, 32318])

```
데이터셋 다운로드: from torch geometric.datasets import PPI
                 ppi = PPI(root="./data/PPI")
첫 번째 서브 그래프 사용: data = ppi[0]
그래프의 노드 개수: data.num_nodes → Number of nodes: 1767
그래프의 엣지 개수: data.edge_index.size(1) → Number of edges: 32318
엣지 인덱스 차원: data.edge index.shape → | Edges shape: torch.Size([2, 32318])
엣지 인덱스 구성: data.edge_index → Edge index:
                                  tensor([[ 0, 0, 0, ..., 1744, 1745, 1749],
                                         [ 372, 1101, 766, ..., 1745, 1744, 1739]])
노드 특성 차원 확인 (50차원) : data.x.shape → Node feature shape: torch.Size([1767, 50])
노드 특성 예시: data.x[0] → Node feature Example:
                          tensor([-0.0855, -0.0884, -0.1128, -0.1719, -0.0766, -0.1003, -0.0751, -0.1149,
                                 -0.1212, -0.0994, 0.0000, -0.1699, -0.0428, -0.1123, -0.0760, -0.1152,
                                 -0.1031, -0.1120, -0.1435, -0.0975, -0.0875, -0.1457, -0.1234, -0.1242,
                                 -0.0976, -0.1197, -0.1161, -0.0735, -0.0667, -0.0873, -0.1797, -0.1447,
                                 -0.1606, -0.1582, -0.1477, -0.4350, -0.1617, -0.1556, -0.1526, -0.1396,
                                 -0.1281, -0.1539, -0.1593, -0.1546, -0.1466, -0.1449, -0.1568, -0.1399,
                                 -0.1494, -0.1481
```



Step 1. Load dataset

```
from torch_geometric.transforms import RandomLinkSplit

# 데이터셋 분리 (학습, 검증, 테스트)

# RandomLinkSplit은 데이터를 학습, 검증, 테스트 세트로 나눕니다.

# 엣지의 70%를 학습용, 10%를 검증용, 20%를 테스트용으로 사용합니다.

transform = RandomLinkSplit(
    num_val=0.1,
    num_test=0.2,
    add_negative_train_samples=False,
    disjoint_train_ratio=0.3,
    neg_sampling_ratio=0)

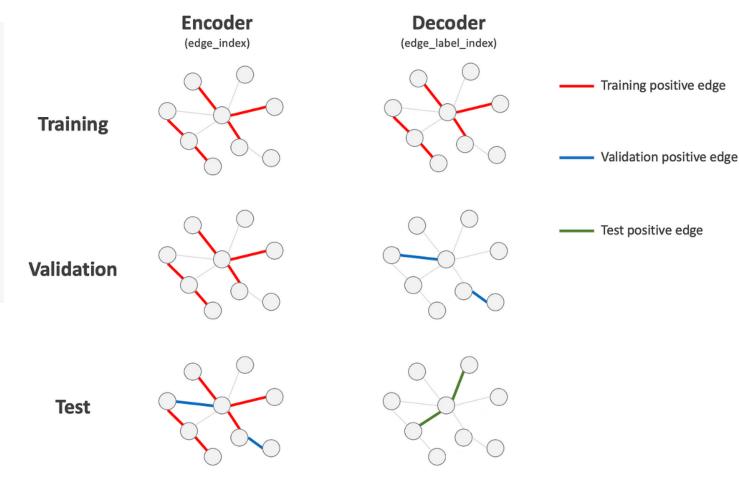
train_data, val_data, test_data = transform(data)

print("Train: ", train_data)

print("Validation: ", val_data)

print("Test: ", test_data)
```

Encoder: Grpah 구조 학습을 위한 Link Decoder: Supervision을 위해 사용하는 Link

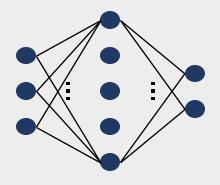


Train: Data(x=[1767, 50], edge_index=[2, 15837], edge_label=[6787], edge_label_index=[2, 6787])
Validation: Data(x=[1767, 50], edge_index=[2, 22624], edge_label=[3231], edge_label_index=[2, 3231])
Test: Data(x=[1767, 50], edge_index=[2, 25855], edge_label=[6463], edge_label_index=[2, 6463])

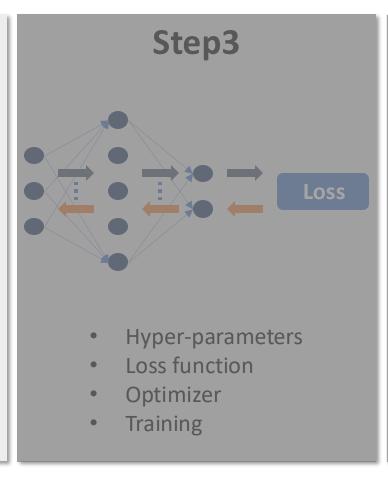


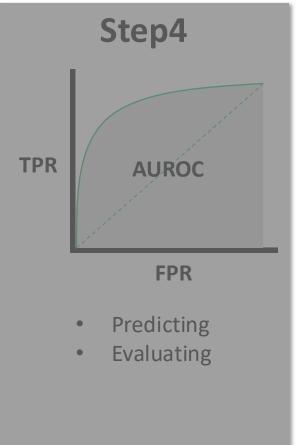
Step1 Data Data Data Collecting data Preprocessing Dataset Data-loader

Step2



- Selecting method
- Building model

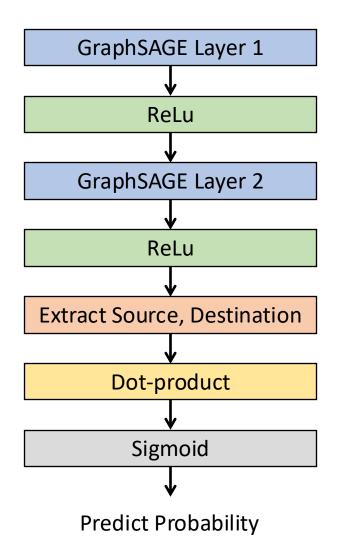




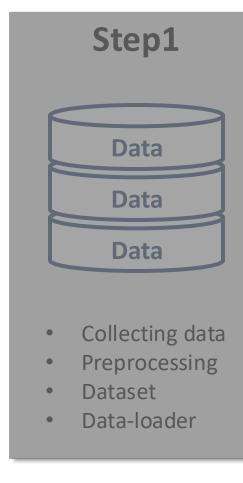


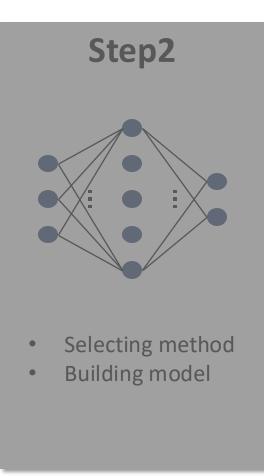
Step 2. Build model

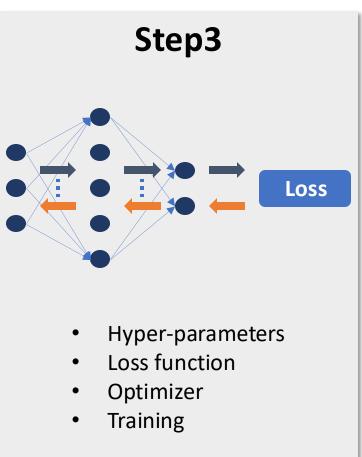
```
import torch
import torch.nn as nn
import torch.nn.functional as F
from torch_geometric.nn import SAGEConv
# 모델 정의
# GraphSAGE 레이어를 사용하는 모델 정의
class GNNForLinkPrediction(nn.Module):
   def __init__(self, in_channels, hidden_channels):
       super().__init__()
       # SAGEConv 레이어 정의
       self.conv1 = SAGEConv((-1, -1), hidden_channels) # 첫 번째 GraphSAGE 레이어
       self.conv2 = SAGEConv(hidden_channels, hidden_channels) # 두 번째 GraphSAGE 레이어
   def forward(self, x, edge_index, edge_label_index):
       # 첫 번째 GraphSAGE 레이어를 통과시키고 ReLU 활성화 함수 적용
       x = F.relu(self.conv1(x, edge_index))
       # 두 번째 GraphSAGE 레이어를 통과
       x = F.relu(self.conv2(x, edge_index))
       src, dst = edge_label_index
       # 소스 및 타겟 노드의 임베딩 추출 및 점곱 계산
       src, dst = edge_label_index # 엣지의 소스와 타겟 노드 인덱스
       edge_pred = torch.sigmoid((x[src] * x[dst]).sum(dim=-1)) # dotproduct로 스칼라 값 출력
       return edge_pred
# 모델 초기화
model = GNNForLinkPrediction(
   in_channels=train_data.num_features,
   hidden_channels=64 # 은닉층의 차원
```

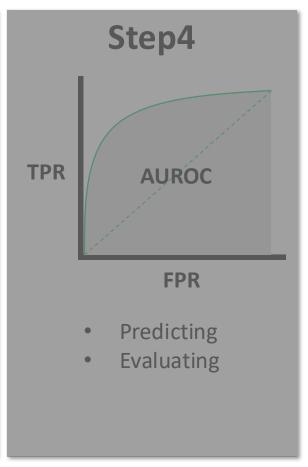














Batch 생성을 위한 Subgraph 생성하는 Loader 구성 사용하는 Data(Train, Validation, Test)에 대해 각각 모두 구성 필요 [torch geometric의 LinkNeighborLoader Option]

- batch_size : Batch 크기
- edge_label_index : Supervision에 사용하는 엣지 인덱스
- num_neighbors : 각 Layer에서 샘플링할 이웃 노드 수
- neg_sampling_ratio : negative edge를 생성할 비율 (positive edge 대비)
- shuffle : Data shuffle 여부

Training의 경우에만, 특정 패턴 학습에 대한 overfitting 방지를 위해 True

```
from torch geometric.loader import LinkNeighborLoader
# 데이터 로더 설정
# LinkNeighborLoader는 이웃 노드 샘플링을 통해 배치를 생성합니다.
train_loader = LinkNeighborLoader(
   train_data,
   batch_size=32, # 배치 크기
   edge_label_index=train_data.edge_label_index, # 학습용 엣지 레이블 인덱스
   num_neighbors=[10, 10], # 각 레이어에서 샘플링할 이웃 노드 수
   neg_sampling_ratio=1.0, # negative edge를 positive edge 수의 1배로 샘플링
   shuffle=True
val_loader = LinkNeighborLoader(
   val_data,
   batch size=32,
   edge_label_index=val_data.edge_label_index,
   num_neighbors=[10, 10],
   neg_sampling_ratio=1.0,
    shuffle=False
test_loader = LinkNeighborLoader(
   test_data,
   batch_size=32,
   edge label index=test data.edge label index,
   num_neighbors=[10, 10],
   neg_sampling_ratio=1.0,
   shuffle=False
```



Training loop는 각 epoch마다 모든 batch (앞서 생성한 subgraph)를 반복 학습하며 각 Batch 마다 모델이 손실(loss)를 계산하며, 이를 역전파(Backpropagation)로 가중치를 업데이트

```
# 학습 및 검증
for epoch in range(10):
   print(f"\nEpoch {epoch+1}:")
   train_loss = train() # 학습 수행
   val_loss, val_auc, _, _ = evaluate(val_loader, epoch, mode="Validation")
   print(f"Train Loss: {train_loss:.4f}, Validation Loss: {val_loss:.4f}")
# 학습 루프 정의
def train():
   model.train() # 모델을 학습 모드로 설정
   total_loss = 0
    loop = tgdm(train loader, desc="Training") # tgdm으로 학습 상태 표시
   for batch in loop:
       optimizer.zero_grad() # 옵티마이저의 그래디언트 초기화
       edge_pred = model(batch.x, batch.edge_index, batch.edge_label_index) # 모델 출력 계산
       loss = criterion(edge_pred, batch.edge_label.float()) # 손실 계산
       loss.backward() # 역전파 단계
       optimizer.step() # 가중치 업데이트
       total_loss += loss.item()
       loop.set_postfix(loss=loss.item()) # tqdm 진행 상태에 현재 손실 표시
   avg_loss = total_loss / len(train_loader)
   writer.add_scalar("Loss/Train", avg_loss, epoch) # TensorBoard 기록
    return avg_loss
```



Validation 단계에서는 모델의 성능을 평가하는 과정으로, 가중치 업데이트를 진행하지 않음 model.eval()을 통해 모델을 평가 모드로 설정

with torch._no_grad()를 사용하여 미분 계산을 비활성화하여 메모리 사용을 줄이고 계산 속도를 높임

```
# 평가 함수 정의
def evaluate(loader, epoch, mode="Validation"):
   model.eval() # 모델을 평가 모드로 설정
   preds, labels = [], []
   loop = tqdm(loader, desc="Evaluating") # tqdm으로 평가 상태 표시
   with torch.no grad(): # 그래디언트 계산 비활성화
       for batch in loop:
           edge_pred = model(batch.x, batch.edge_index, batch.edge_label_index) # 모델 출력 계산
           preds.append(edge pred.cpu()) # 예측값 저장
           labels.append(batch.edge label.cpu()) # 실제 라벨 저장
   preds, labels = torch.cat(preds), torch.cat(labels)
   loss = criterion(preds, labels.float()).item()
   auc = roc_auc_score(labels, preds)
   writer.add_scalar(f"Loss/{mode}", loss, epoch) # TensorBoard 기록
   writer.add_scalar(f"AUC/{mode}", auc, epoch)
   return loss, auc, preds, labels
```

```
Epoch 1:
Training: 100% | 213/213 [00:03<00:00, 68.09it/s, loss=0.81]
Evaluating: 100% | 101/101 [00:00<00:00, 180.07it/s]

Train Loss: 0.6756, Validation Loss: 0.6614

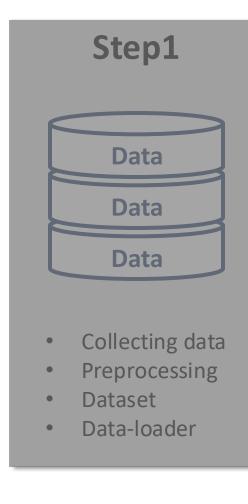
...

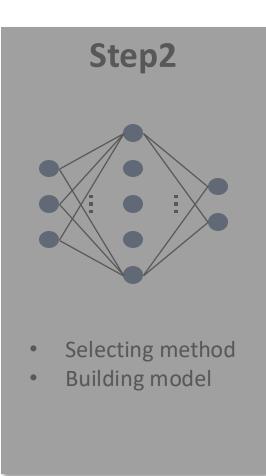
Epoch 10:
Training: 100% | 213/213 [00:03<00:00, 63.33it/s, loss=0.462]
Evaluating: 100% | 101/101 [00:00<00:00, 175.79it/s]

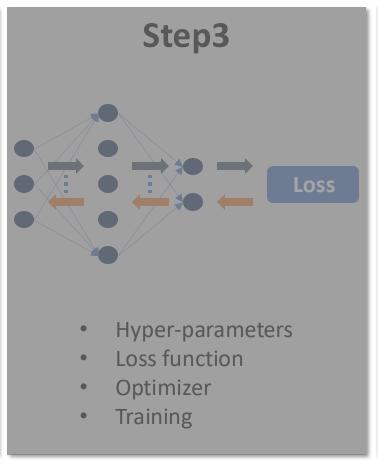
Train Loss: 0.5936, Validation Loss: 0.6256
```

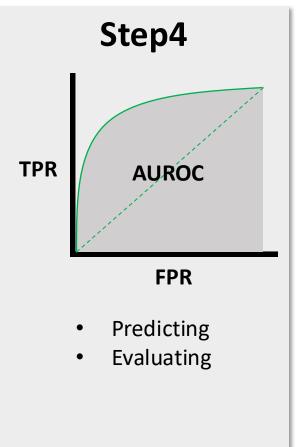
→ Validation Loss도 함께 확인하여 모델 Overfitting 정도 확인













Step 4. Evaluation

모델 학습이 모두 완료된 후, 테스트 데이터에 대한 모델 성능 평가 진행 평가 방식: AUC-ROC



Step 4. Evaluation

테스트 데이터에서 실제 예측이 어떻게 이루어졌는지 5개의 예시 확인

Prediction Probability: 0.7808, Predicted Label: 1, Ground Truth: 1.0

```
# 테스트 데이터에서 예측 예시 출력
def print_test_examples(num_examples=5):
   #테스트 데이터에서 예측값, 실제값, 원래 엣지 정보를 출력합니다.
   for i in range(num_examples): # num_examples만큼 출력
       # 테스트 데이터의 원래 엣지 인덱스 추출
       test edge index = test data.edge label index[:, i] # 원래 엣지의 (src, dst) 인덱스
       test_edge_src, test_edge_dst = test_edge_index[0].item(), test_edge_index[1].item()
       # 모델의 예측값과 실제 라벨
       test_example_pred = test_preds[i].item()
       test example label = test labels[i].item()
       predicted label = 1 if test example pred > 0.5 else 0 # 예측 라벨 계산 threshold 0.5
       # 결과 출력
       print(f"Test Edge {i + 1}: (src: {test edge src}, dst: {test edge dst})")
       print(f"Prediction Probability: {test example pred:.4f}, Predicted Label; {predicted label}, Ground Truth: {test example label}\n")
# 테스트 예시 출력
print_test_examples(num_examples=5) # 상위 5개 예시 출력
Test Edge 1: (src: 1518, dst: 498)
Prediction Probability: 0.8915, Predicted Label: 1, Ground Truth: 1.0
                                                                → 1518번 단백질과 498번 단백질은 모델의 예측 확률이 0.8915임으로
                                                                    threshold 0.5에 따라 관계가 존재하는 것으로 예측했으며,
Test Edge 2: (src: 1053, dst: 496)
                                                                    실제 정답도 관계가 존재하는 것으로 나타남
Prediction Probability: 0.9009, Predicted Label: 1, Ground Truth: 1.0
Test Edge 3: (src: 425, dst: 366)
Prediction Probability: 0.5270, Predicted Label: 1, Ground Truth: 1.0
Test Edge 4: (src: 311, dst: 646)
Prediction Probability: 0.8610, Predicted Label: 1, Ground Truth: 1.0
Test Edge 5: (src: 1497, dst: 890)
```



Visualization

```
# TensorBoard
print("To visualize results in Colab, run:")
print("%load_ext tensorboard")
print(f"%tensorboard --logdir {log_dir}")
writer.close()
```

```
%load_ext tensorboard
%tensorboard --logdir /content/runs/ppi_link_prediction
```

